Documentation technique
Version 1.0 — 5 mars 2026

Panel de données administratives

Panel de salariés de la fonction publique de 2015 à 2025

Pipeline de consolidation et d'analyse
des données administratives de paie

Destinataires : Analystes de données, économistes, nouveaux arrivants

Prérequis : Notions de base Python, accès MinIO

Équipe : Équipe Data et Equipe Stat-Eco

Résumé exécutif

Ce document décrit l'intégralité du **pipeline de consolidation et d'analyse de la masse salariale administrative** couvrant la période 2015 à 2025. Il s'adresse à toute personne rejoignant le projet.

Information

À partir de fichiers Excel mensuels bruts déposés dans MinIO, ce pipeline :

1. **Valide** la structure des données sources
2. **Convertit et nettoie** les données (Bronze $\rightarrow$ Silver) en appliquant les référentiels ANSTAT
3. **Enrichit** chaque agent avec ses codes institutionnels (organisme, grade, emploi, CITP...)
4. **Impute** les grades invalides par une méthode statistique en cascade
5. **Construit** un panel longitudinal individu $\times$ période sur 10 ans
6. **Calcule** des indicateurs salariaux complets (P25/P75, grade, sexe, CITP)
7. **Produit** un fichier Excel navigable pour les économistes et décideurs

Architecture en médaillon. Le pipeline organise les données en trois couches de qualité croissante :

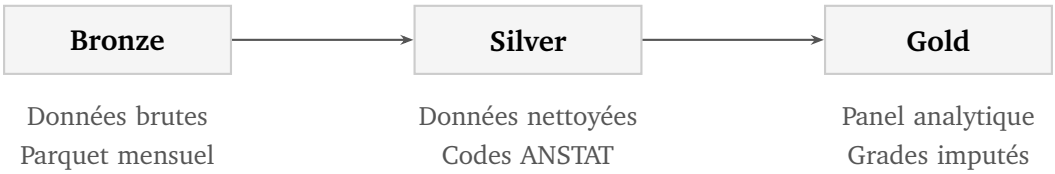

Table des matières

Résumé exécutif **1**

1 Contexte et objectifs **4**
1.1 Présentation générale 4
1.2 Problèmes à résoudre 4
1.3 Où des lignes sont-elles supprimées ? 4
1.4 Livrables produits 5

2 Architecture technique **6**
2.1 Environnement et prérequis 6
2.2 Organisation du stockage 6
2.3 Séquence du pipeline 7

3 Description des scripts **8**
3.1 01_pre_analyse.py 8
3.2 02_staging_to_bronze.py 9
3.3 03_bronze_to_silver.py 9
3.3.1 Normalisation pour le matching 9
3.3.2 Référentiels ANSTAT chargés 9
3.3.3 Situations conservées 10
3.3.4 Suivi du matching par période 10
3.4 04_validation_silver.py 10
3.5 05_silver_to_gold.py 10
3.6 06_compiler_panel.py 11
3.7 06b_imputer_grades.py 11
3.7.1 Pourquoi cette étape ? 11
3.7.2 Cascade emploi sur 3 niveaux 11
3.7.3 Colonne GRADE_SOURCE 11
3.7.4 Grades valides reconnus 12
3.8 07_calcul_indicateur.py 12
3.8.1 Paramètres de configuration 12
3.8.2 Calcul du salaire brut 12
3.8.3 Indicateurs et feuilles produites 13
3.9 08_creation_fichier_excel_avec_sommaire.py 13

4 L'orchestrateur **14**
4.1 Présentation et utilisation 14
4.2 Comportement en cas d'erreur 14

5 Guide de démarrage rapide **15**
5.1 Première exécution 15
5.2 Erreurs fréquentes 16
5.3 Scénarios courants 16

6 Référence rapide **17**
6.1 Séquence des scripts 17
6.2 Colonnes clés du panel Gold 17
6.3 Nomenclature CITP 18

7 Glossaire **19**

CHAPITRE 1

Contexte et objectifs

1.1 Présentation générale

Ce projet consolide les données administratives de paie de la fonction publique produites mensuellement entre 2015 et 2025. Chaque mois, le système source génère deux feuilles Excel :

— **Feuille F1** — données nominatives (matricule, nom, grade, organisme, montants...)

— **Feuille F2** — décomposition de la rémunération par codes numériques

L'objectif est d'assembler ces 120+ fichiers en un **panel longitudinal cohérent** pour analyser l'évolution des rémunérations et effectifs sur dix années.

1.2 Problèmes à résoudre

Problème	Description
Instabilité des colonnes	Les noms changent d'une année à l'autre. Un mapping par expressions régulières est nécessaire.
Codes de paie variables	Les codes numériques F2 apparaissent et disparaissent selon les évolutions réglementaires.
Grades invalides	Une fraction des agents a un grade mal renseigné (`B7`, `C7`, valeur vide).
Libellés non standardisés	Les noms d'organismes et de grades varient orthographiquement selon les périodes.
Multi-postes	Certains agents apparaissent plusieurs fois dans un même mois.
Volumétrie	10 ans de données mensuelles = dizaines de millions de lignes.

1.3 Où des lignes sont-elles supprimées ?

Étape	Condition	Portée
02	Colonnes clés absentes (`matricule`, `montant_brut`...)	Mois entier ignoré
02	Situation administrative non reconnue ou vide	Lignes individuelles + données F2 associées
05	Sexe inconnu ou vide	Lignes retirées avant les calculs
05	Grade invalide non imputable ou salaire ≤ 0	Exclusion des agrégations uniquement

Le filtrage sur les situations (étape 02) supprime aussi les données F2 des agents concernés, car la jointure F1 $\times$ F2 s'effectue *après* ce filtrage. Les composantes élémentaires de paie de ces agents sont perdues.

1.4 Livrables produits

Type	Emplacement
Panel annuel	`gold/panel_admin/panel_YYYY.parquet`
Panel complet	`gold/panel_admin/panel_complet.parquet`
Agrégats mensuels	`gold/panel_admin/masse_salariale.parquet`
Indicateurs	`staging/panel_admin/exports_gold/indicateurs_*.xlsx`
Excel navigable	`staging/panel_admin/exports_gold/*_SOMMAIRE.xlsx`
Rapports qualité	`staging/panel_admin/validation/*.csv`

CHAPITRE 2

Architecture technique

2.1 Environnement et prérequis

Le pipeline fonctionne sur **JupyterHub** (Kubernetes) ou localement. Chaque script contient deux blocs de configuration — commentez l'un, décommentez l'autre selon votre environnement.

Listing 2.1 – Installation des dépendances

```
pip install polars fastexcel boto3 python-dotenv openpyxl
```

Listing 2.2 – Fichier .env à la racine du projet

```
MINIO_ENDPOINT=http://192.168.1.230:30137
MINIO_ACCESS_KEY=datalab-team
MINIO_SECRET_KEY=minio-datalabteam123
```

Bibliothèque	Rôle	Pourquoi
`polars`	Traitement des données	Très rapide, faible mémoire. Remplace pandas sur les gros volumes.
`boto3`	Accès MinIO/S3	Client S3 standard, compatible MinIO.
`fastexcel`	Lecture Excel	Haute performance, utilisé par Polars.
`openpyxl`	Écriture Excel	Production des fichiers Excel mis en forme.
`python-dotenv`	Configuration	Variables d'environnement sans secrets codés en dur.

2.2 Organisation du stockage

```
staging/
  panel_admin/fichiers_mensuels/   # Fichiers Excel sources
  panel_admin/references/          # ANSTAT_CODES.xlsx
  panel_admin/pre_analyse/         # Rapports CSV de pre-
     analyse
  panel_admin/validation/          # Rapports qualite
```

```
  panel_admin/exports_gold/        # Fichiers Excel de sortie

bronze/  panel_admin/              # 012015.parquet, 022015.
   parquet, ...
silver/  panel_admin/              # 2015.parquet, ..., 2025.
   parquet
gold/    panel_admin/              # panel_YYYY.parquet,
   panel_complet.parquet
```

2.3 Séquence du pipeline

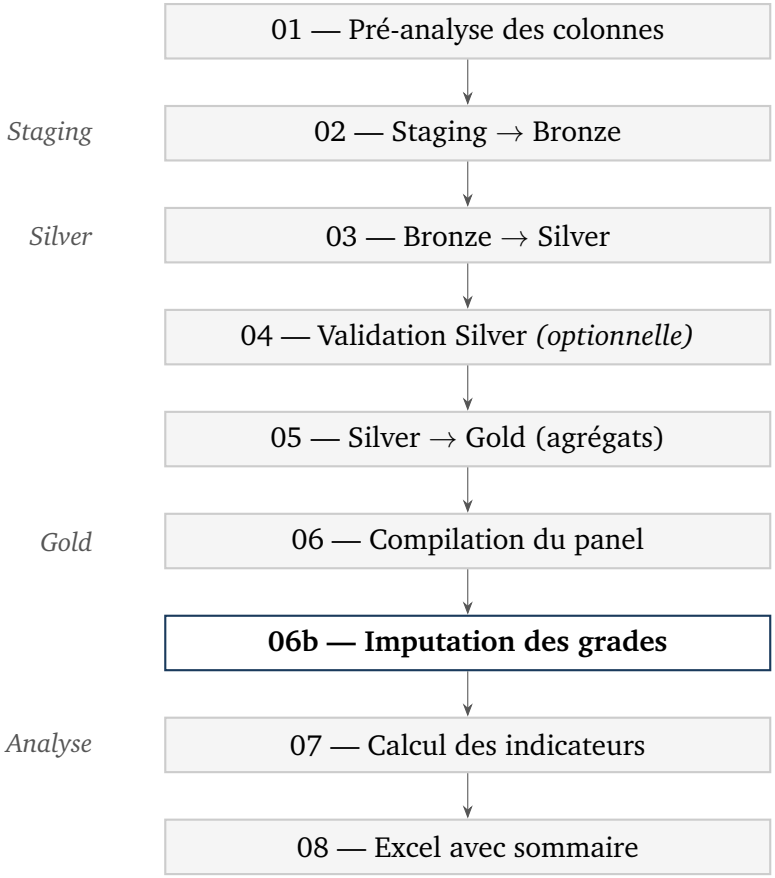

CHAPITRE 3

Description des scripts

3.1 01_pre_analyse.py

Ce script est le **premier à exécuter** lors de l'intégration de nouveaux fichiers. Il lit uniquement les en-têtes (sans charger les données) et produit des rapports sur l'évolution de la structure entre périodes.

> **Note**
>
> Ce script ne modifie aucune donnée. Il peut être relancé autant de fois que nécessaire sans risque.

Analyses réalisées :

- Comptage du nombre de colonnes F1 et F2 par période
- Détection des colonnes F1 apparues / disparues entre périodes consécutives
- Détection des codes numériques F2 apparus / disparus entre périodes
- Min, max, moyenne du nombre de colonnes par fichier
- Min et max des valeurs numériques des codes F2 sur toutes les périodes

Fichiers produits (dans `staging/panel_admin/pre_analyse/`) :

Fichier	Contenu
`colonnes_f1_uniques.csv`	Toutes les colonnes F1 rencontrées
`codes_f2_uniques.csv`	Tous les codes numériques F2
`stats_par_periode.csv`	Nombre de colonnes F1, F2 et codes par période
`changements_f1.csv`	Colonnes apparues/disparues entre périodes
`changements_codes_f2.csv`	Codes numériques apparus/disparus entre périodes

> **Conseil pratique**
>
> **Une colonne F1 disparaît :** vérifier si elle a été renommée (visible dans les colonnes *apparues* de la même transition) ou si elle a réellement disparu.
> **Un code F2 disparaît :** modification réglementaire probable. Vérifier si le calcul du salaire brut par composantes est affecté.

3.2 02_staging_to_bronze.py

Ce script convertit les fichiers Excel mensuels en Parquet dans le bucket Bronze. Le format Parquet est 10 à 20 fois plus compact que Excel et nettement plus rapide à lire.

Pour chaque fichier mensuel :

1. Lecture de la feuille F1
2. Lecture de la feuille F2 (composantes élémentaires)
3. Fusion sur le matricule (*left join sur F1 après filtrage des situations*)
4. Ajout de `mois_annee` extrait du nom de fichier
5. Écriture en Parquet compressé Snappy

3.3 03_bronze_to_silver.py

C'est l'étape de **transformation centrale**. Elle produit des données nettoyées, normalisées et enrichies avec les codes institutionnels ANSTAT.

3.3.1 Normalisation pour le matching

Les libellés source et les codes ANSTAT sont normalisés de façon identique avant comparaison : suppression des accents et de la ponctuation, mise en majuscules. Cela rend le matching robuste aux variations orthographiques.

3.3.2 Référentiels ANSTAT chargés

Code	Onglet source	Description
`CODE_ORGANISME`	ORGANISME_OK	Identifiant institutionnel de l'organisme
`CODE_GRADE`	GRADE	Code du grade administratif
`CODE_EMPLOI`	HISTORIQUE_ECHELLES_CORPS	Corps/emploi, code CITP, métier
`CODE_AFFECTATION`	lieu affectation	Lieu, région, département
`CODE_SERVICE`	SERVICE	Service d'affectation
`CODE_FONCTION`	FONCTION	Fonction occupée
`CODE_POSTE`	LIBELLE POSTE	Libellé du poste
`CODE_POSITION_SOLDE`	CODE_SITUATION_SOLDE	Position administrative

3.3.3 Situations conservées

Valeur conservée	Libellés source reconnus
`en_activite`	EN ACTIVITE, ACTIVITE
`regul_indemnites`	REGUL. INDEMNITES, REGULARISATION INDEMNITES
`demi_solde`	DEMI-SOLDE, DEMI SOLDE, 1/2 SOLDE
(supprimé)	Tout autre libellé

3.3.4 Suivi du matching par période

Le script calcule pour chaque mois le taux de matching de chaque code et produit `taux_matching_anstat_par_periode.csv`. Un taux inférieur à 80% pour CODE_GRADE ou CODE_ORGANISME mérite investigation.

3.4 04_validation_silver.py

Cinq contrôles qualité, sans modification des données.

> **Note**
>
> Étape **optionnelle** : un échec ne bloque pas la suite. Fortement recommandée lors de la première intégration.

Contrôle	Description
1. Complétude	% de valeurs non nulles par colonne clé. Alerte si $< 95\%$.
2. Variations NA	Taux de NA par année. Colonne suspecte si variation > 90 points.
3. Doublons	Agents présents plusieurs fois par mois (`matricule × mois_annee`).
4. Cohérence montants	Lignes où `montant_net > montant_brut`.
5. Distribution situations	Fréquence de chaque situation administrative.

3.5 05_silver_to_gold.py

Agrégats mensuels par organisme et situation. Pour chaque combinaison `mois_annee × organisme ×` calcule : somme, moyenne, médiane de `montant_brut` et `montant_net`, nombre d'agents, effectifs par sexe.

3.6 06_compiler_panel.py

Assemble les Silver annuels en panel longitudinal **individu** × **période** : concaténation, déduplication sur `matricule × mois_annee`, tri chronologique, écriture en Parquet par année et en fichier complet.

> Les colonnes `GRADE` et `GRADE_SOURCE` ne sont pas encore présentes ici. Ne pas utiliser ces fichiers Gold pour des analyses de grade avant l'exécution de 06b.

3.7 06b_imputer_grades.py

3.7.1 Pourquoi cette étape ?

Une fraction des agents a un grade invalide (`B7`, `C7`, `D7`, ou valeur sans chiffre). La méthode utilise le **grade modal par emploi** calculé sur l'intégralité de l'historique (10 ans), ce qui garantit une meilleure qualité qu'un traitement année par année.

3.7.2 Cascade emploi sur 3 niveaux

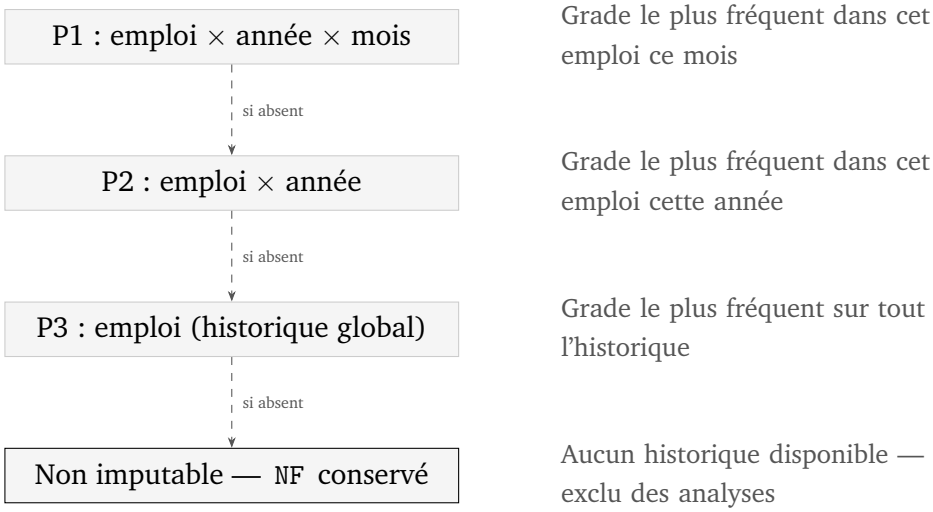

3.7.3 Colonne GRADE_SOURCE

Valeur	Signification
`OBSERVE`	Grade valide dans la source, aucune modification.
`IMPUTE`	Grade invalide remplacé par la cascade emploi.
`NF_NON_IMPUTABLE`	Aucun historique disponible — exclu des analyses par grade.

Conseil pratique

Analyse conservatrice : filtrer sur `GRADE_SOURCE = 'OBSERVE'`.
Analyse complète : utiliser `OBSERVE` et `IMPUTE` (comportement par défaut).
Mesure de qualité : calculer la part de `IMPUTE` par année ou par organisme.

3.7.4 Grades valides reconnus

Catégorie	Grades valides	Grades invalides connus
A	A1 à A7	A (sans chiffre)
B	B1 à B6	B (sans chiffre), B7
C	C1 à C5	C (sans chiffre), C7
D	D1 à D3	D (sans chiffre), D7

3.8 07_calcul_indicateur.py

3.8.1 Paramètres de configuration

```
# True = Salaire brut par cle_unique | False = Revenu par
    matricule
MODE_SALAIRE_BRUT = True

# True = annees 2024-2025 | False = 2015 a la derniere annee
PERIODE_RECENTE   = True

# True = inclure salaires nuls | False = salaire strictement
     > 0
INCLURE_ZEROS     = True
```

Listing 3.1 – Paramètres en tête du script

MODE_SALAIRE_BRUT = True (cle_unique) : un agent dans deux organismes est compté deux fois. Utile pour la masse salariale par organisme.

MODE_SALAIRE_BRUT = False (matricule) : les salaires de plusieurs postes sont additionnés. Utile pour le revenu des personnes.

3.8.2 Calcul du salaire brut

$$\text{SALAIRE_BRUT} = \text{code}_{124} + \text{code}_{228} + \text{code}_{271} + \text{code}_{421} + \text{code}_{425}$$

> Si la nomenclature des codes évolue, la variable `COMPOSANTES_SALAIRE` doit être mise à jour par l'équipe métier.

3.8.3 Indicateurs et feuilles produites

Pour chaque dimension (grade, grade × sexe, CITP) : effectif, moyenne, médiane, minimum, maximum, P25, P75.

Feuille	Contenu
`REVENU_Grade_Detail`	Indicateurs complets par grade
`REVENU_Grade_Sexe`	Indicateurs croisés grade × sexe
`REVENU_CITP_Detail`	Indicateurs par code CITP et métier
`SALAIRE_BRUT_Moyen`	Moyenne par année × mois (pivot par grade)
`SALAIRE_BRUT_Median`	Médiane, même structure pivot
`MULTI_Par_Grade_NbPostes`	Effectif par grade et nombre de postes (1 à 5+)
`MULTI_Distribution`	Distribution globale mono/multi-postes

3.9 08_creation_fichier_excel_avec_sommaire.py

Produit un fichier Excel navigable pour les utilisateurs non-techniques. Chaque ligne du sommaire est un lien cliquable vers la feuille de détail correspondante.

Section	Contenu
1. CITP	9 grands groupes professionnels — effectif, nombre de métiers
2. Grade	A1 à D3 — effectif, revenu moyen pondéré
3. Sexe	Homme / Femme — effectif, revenu moyen pondéré
4. Multi-postes	Effectifs mono et multi-postes par grade

CHAPITRE 4

L'orchestrateur

4.1 Présentation et utilisation

L'orchestrateur (`orchestrateur.py`) est le point d'entrée unique du pipeline.

```
python orchestrateur.py                    # pipeline
   complet
python orchestrateur.py --depuis 06b       # reprendre a une
    etape
python orchestrateur.py --etapes 07 08     # etapes
   specifiques
python orchestrateur.py --dry-run          # plan sans
   execution
python orchestrateur.py --depuis 03 --dry-run
```

4.2 Comportement en cas d'erreur

Situation	Étape	Comportement
Code retour $\neq 0$	Obligatoire	Arrêt immédiat. Commande pour reprendre affichée.
Code retour $\neq 0$	Optionnelle (04)	Avertissement, pipeline continue.
Script introuvable	Toutes	Erreur avant de commencer, liste des fichiers manquants.

CHAPITRE 5

Guide de démarrage rapide

5.1 Première exécution

1. **Récupérer les scripts.** Placez tous les fichiers `.py` dans un même dossier.

2. **Créer le fichier `.env`.**

```
MINIO_ENDPOINT=http://192.168.1.230:30137
MINIO_ACCESS_KEY=datalab-team
MINIO_SECRET_KEY=minio-datalabteam123
```

3. **Installer les dépendances.**

```
pip install polars fastexcel boto3 python-dotenv openpyxl
```

4. **Vérifier l'accès MinIO.** Confirmez l'existence des buckets `staging`, `bronze`, `silver` et `gold`.

5. **Déposer les fichiers sources.** Fichiers Excel dans `staging/panel_admin/fichiers_mensuels/` et le référentiel ANSTAT dans `staging/panel_admin/references/`.

6. **Vérifier le plan.**

```
python orchestrateur.py --dry-run
```

7. **Lancer la pré-analyse.**

```
python orchestrateur.py --etapes 01
```

   Vérifiez les rapports dans `staging/panel_admin/pre_analyse/`.

8. **Lancer le pipeline complet.**

```
python orchestrateur.py
```

   Comptez 30 à 60 minutes sur 10 ans de données.

9. **Vérifier la qualité.** Ouvrez `taux_matching_anstat_par_periode.csv` et vérifiez les taux de matching ($> 80\%$ pour CODE_GRADE et CODE_ORGANISME).

10. **Récupérer les sorties.** Téléchargez `*_SOMMAIRE.xlsx` dans `staging/panel_admin/exports_gold`

5.2 Erreurs fréquentes

Message	Cause et solution
`ANSTAT introuvable`	Fichier absent ou nom sans `ANSTAT_CODE`. Vérifier `staging/.../references/`.
`0 fichiers Bronze`	Étape 02 non exécutée. Relancer `-depuis 02`.
`GRADE absente`	Étape 06b non exécutée. Relancer `-depuis 06b`.
`ConnectionError`	Problème réseau. Vérifier l'adresse endpoint dans `.env`.
`Aucune donnée [2024, 2025]`	`PERIODE_RECENTE=True` mais années absentes. Passer à `False`.

5.3 Scénarios courants

Nouveau mois de données : `python orchestrateur.py --depuis 02`

Recalculer les indicateurs : modifier les paramètres dans 07, puis `python orchestrateur.py --etapes 07 08`

Mettre à jour ANSTAT : remplacer le fichier, puis `python orchestrateur.py --depuis 03`

CHAPITRE 6

Référence rapide

6.1 Séquence des scripts

N°	Script	Source	Sortie
01	`01_pre_analyse.py`	staging (Excel)	rapports CSV
02	`02_staging_to_bronze.py`	staging (Excel)	bronze (Parquet)
03	`03_bronze_to_silver.py`	bronze	silver (Parquet)
04	`04_validation_silver.py`	silver	rapports CSV
05	`05_silver_to_gold.py`	silver	gold (agrégats)
06	`06_compiler_panel.py`	silver	gold (panel)
06b	`06b_imputer_grades.py`	gold (panel)	gold (panel + GRADE
07	`07_calcul_indicateur.py`	gold	Excel indicateurs
08	`08_creation_fichier_excel_avec_sommaire.py`	Excel 07	Excel sommaire

6.2 Colonnes clés du panel Gold

Colonne	Type	Description
`matricule`	Texte	Identifiant unique de l'agent
`cle_unique`	Texte	Matricule || Code organisme
`mois_annee`	Texte	Période au format MMYYYY
`montant_brut`	Décimal	Rémunération brute mensuelle
`montant_net`	Décimal	Rémunération nette mensuelle
`situation_normalisee`	Texte	en_activite / regul_indemnites / demi_solde
`CODE_ORGANISME`	Texte	Code institutionnel (ANSTAT)
`CODE_GRADE`	Texte	Code du grade (ANSTAT)
`CODE_EMPLOI`	Texte	Code du corps/emploi
`Code_CITP`	Texte	Code CITP à 4 chiffres
`Metier_CITP`	Texte	Libellé du métier
`GRADE`	Texte	Grade final (après imputation éventuelle)

Colonne	Type	Description
`GRADE_SOURCE`	Texte	OBSERVE / IMPUTE / NF_NON_IMPUTABLE
`124, 228, 271...`	Décimal	Composantes élémentaires du salaire brut

6.3 Nomenclature CITP

Code	Grand groupe
1	Directeurs, cadres de direction et gérants
2	Professions intellectuelles et scientifiques
3	Professions intermédiaires
4	Employés de type administratif
5	Personnel des services directs aux particuliers
6	Agriculteurs et ouvriers qualifiés de l'agriculture
7	Métiers qualifiés de l'industrie et de l'artisanat
8	Conducteurs d'installations et de machines
9	Professions élémentaires

CHAPITRE 7

Glossaire

Terme	Définition
Agent	Fonctionnaire ou agent de l'État, identifié par son matricule.
ANSTAT	Système de référencement statistique. Le fichier ANSTAT_CODES.xlsx contient les tables de correspondance entre libellés et codes standardisés.
Bronze	Première couche. Données brutes converties en Parquet, sans transformation métier.
CITP	Classification Internationale Type des Professions. 9 grands groupes.
cle_unique	Clé composite : matricule || code_organisme.
Code de paie	Code numérique identifiant une composante de la rémunération (ex. 124 = traitement indiciaire).
F1 / F2	Feuilles des fichiers Excel mensuels. F1 : données nominatives. F2 : décomposition par codes numériques.
Gold	Troisième couche. Panel individu × période, avec grades imputés.
Grade	Position hiérarchique dans la grille (ex. A3, B2, C1).
GRADE_SOURCE	Traçabilité du grade : OBSERVE, IMPUTE ou NF_NON_IMPUTABLE.
Imputation	Remplacement d'une valeur invalide par une estimation statistique.
Matricule	Identifiant unique d'un agent au sein d'un organisme.
Medallion architecture	Architecture à trois couches (Bronze, Silver, Gold).
MinIO	Système de stockage objet compatible avec l'API Amazon S3.
Multi-postes	Agent cumulant plusieurs postes dans le même mois.
P25 / P75	Premier et troisième quartiles de la distribution salariale.
Panel	Table organisée en individus × périodes.

Terme	Définition
Parquet	Format de fichier en colonnes, efficace pour le stockage analytique.
Silver	Deuxième couche. Données nettoyées et enrichies avec les codes ANSTAT.
Snappy	Algorithme de compression utilisé pour les fichiers Parquet.