# Note méthodologique
# Calcul des indicateurs de revenu des agents de l'administration publique

ANSTAT – Direction des Données et de l'Innovation (DDI)

Version du 17 octobre 2026

## Table des matières

**1 Objet de la note** **3**

**2 Sources et chaîne de traitement** **3**
2.1 Sources administratives . . . 3
2.2 Référentiels . . . 4
2.3 Architecture en couches . . . 4
2.4 Étapes . . . 4

**3 Ingestion et normalisation** **5**
3.1 Lecture des fichiers (étape 02) . . . 5
3.2 Standardisation (étape 03) . . . 6

**4 Unité statistique et période** **6**
4.1 Identifiants . . . 7
4.2 Unité d'observation . . . 7
4.3 Période . . . 7

**5 Imputations en couche Silver** **7**
5.1 Grade . . . 7
5.2 Montants brut et net . . . 8
5.3 Contrôles de qualité (étape 04) . . . 8

**6 Construction du panel** **8**
6.1 Unicité et multi-postes . . . 8
6.2 Variables de revenu construites . . . 9

**7 Définitions du revenu** **9**
7.1 M1 : salaire strict de référence . . . 9
7.2 M2 : salaire brut total . . . 9
7.3 M3 : salaire brut total hors barèmes spécifiques . . . 10

**8 Population retenue** **10**
8.1 Filtres communs (étape 07) . . . . . 10
8.2 Exclusions propres à chaque mesure (étape 07b) . . . . . 10

**9 Conformité au barème** **11**
9.1 Secteur de barème . . . . . 11
9.2 Bornes de référence . . . . . 11
9.3 Statuts . . . . . 11
9.4 Tolérance de 5 % . . . . . 11

**10 Correction des hors-barème temporaires** **12**

**11 Gouvernance des règles sensibles** **12**

**12 Indicateurs produits** **13**
12.1 Unité et statistiques . . . . . 13
12.2 Indicateurs par mesure . . . . . 14
12.3 Multi-postes . . . . . 14
12.4 Autres tableaux . . . . . 14

**13 Sorties statistiques** **15**
13.1 Classeur final (étape 08) . . . . . 15
13.2 Base PostgreSQL (étape 09) . . . . . 15
13.3 Vues Superset (étape 10) . . . . . 16

**14 Traitements complémentaires** **16**
14.1 Correction des trajectoires individuelles . . . . . 16
14.2 Salaire par expérience . . . . . 16
14.3 Exports . . . . . 17

**15 Limites d'interprétation** **17**

**16 Synthèse méthodologique** **18**

# 1 Objet de la note

La présente note décrit la méthodologie retenue par l'ANSTAT, Direction des Données et de l'Innovation (DDI), pour produire les indicateurs de revenu issus des données administratives de paie. Elle formalise les définitions statistiques, le périmètre de population, les traitements de qualité et les indicateurs produits par le pipeline *Panel Admin*.

La présente version décrit les traitements appliqués par le code de la branche `main` du dépôt au 17 octobre 2026 : ingestion, normalisation, imputations, construction du panel, contrôle de conformité au barème, production des indicateurs, fichiers Excel et alimentation de PostgreSQL et Superset.

**Principe directeur**

Les indicateurs de revenu sont calculés uniquement sur des agents fonctionnaires dont le grade, le secteur de barème et le salaire sont exploitables, et dont le salaire est conforme au barème officiel de l'État. Le pipeline produit trois mesures : le salaire strict de référence (M1), le salaire brut total (M2), et le salaire brut total hors barèmes spécifiques (M3).

# 2 Sources et chaîne de traitement

## 2.1 Sources administratives

Les données sources sont les fichiers Excel mensuels de paie de l'administration publique, un fichier par mois. Chaque fichier comporte deux feuilles :

— la feuille principale, dite F1, contient l'identité administrative de l'agent, sa situation, son organisme, son emploi, son grade, sa classe-échelon et les montants agrégés de paie (brut, net, retenues) ;
— la feuille de détail, dite F2, contient un montant par code poste de rémunération (salaire de base, indemnités, allocations). Elle sert à reconstruire les composantes du salaire.

## 2.2 Référentiels

| Référentiel | Usage |
|---|---|
| `FICHIER_ANSTAT_CODE_2025.xlsx` | Codification ANSTAT : lieux d'affectation, organismes, positions de solde, emplois (avec code et métier CITP), services, fonctions, grades et postes (étape 03). |
| `CORRESPONDANCE_GRILLE_EMPLOI.xlsx` | Rattachement de chaque emploi à un secteur de barème (étapes 07 et 07b). |
| `anstat_2025.txt.xlsx` | Grille salariale de référence par secteur de barème et grade, qui fournit les bornes de conformité (étape 07). |
| Indice harmonisé des prix (IHPC) | Déflation des revenus dans le classeur final (étape 08). Les valeurs sont saisies dans le script. |

## 2.3 Architecture en couches

La production suit une architecture en couches, stockées dans MinIO :

**Staging** dépôt des fichiers Excel mensuels et des référentiels ;

**Bronze** un fichier Parquet par mois, F2 rattachée à F1, toutes les valeurs conservées en texte ;

**Silver** un fichier Parquet par année : noms de colonnes standardisés, situations administratives filtrées, codes ANSTAT ajoutés, montants convertis, grades et salaires manquants imputés ;

**Gold** panel agent $\times$ mois, statuts de conformité au barème, corrections des hors-barème et sorties statistiques.

## 2.4 Étapes

L'orchestrateur `orchestrateur.py` enchaîne les étapes suivantes, dans cet ordre. L'échec d'une étape arrête la chaîne, sauf pour les étapes 00 et 04.

| Étape | Script | Rôle |
|---|---|---|
| 00 | `00_upload_staging` | Dépôt des fichiers sources dans Staging |
| 01 | `01_pre_analyse` | Inventaire descriptif des colonnes F1 et des codes F2 |
| 02 | `02_staging_to_bronze` | Conversion Excel vers Parquet, rattachement F2 à F1 |
| 03 | `03_bronze_to_silver` | Normalisation, filtre des situations, codes ANSTAT |
| 03b | `03b_imputer_grades_silver` | Extraction et imputation du grade |
| 03c | `03c_imputer_salaires_silver` | Imputation des montants brut et net manquants |
| 04 | `04_validation_silver` | Contrôles de qualité (signalement seul) |
| 05 | `05_silver_to_gold` | Agrégats de masse salariale et d'effectifs |
| 06 | `06_compiler_panel` | Panel agent × mois, mesures M1 et M2 |
| 07 | `07_calcul_indicateur` | Population, barème, statuts de conformité |
| 07a | `07a_imputer_hors_bareme` | Correction des hors-barème temporaires |
| 07b | `07b_calcul_indicateurs` | Indicateurs M1, M2 et M3 |
| 08 | `08_creation_fichier_excel_avec_sommaire` | Classeur final avec sommaires annuels |
| 09 | `09_charger_panel_pg` | Chargement de la base dans PostgreSQL |
| 10 | `10_validate_superset_views` | Déploiement et validation des vues Superset |

Les traitements suivants sont lancés séparément, hors orchestrateur : la correction des trajectoires individuelles (`10_correction_gold_trajectoire`), l'analyse du salaire par expérience (`11_analyse_salaire_experience` et `plus_age_experience`) et les exports `export_salaires_sexe` et `export_liste_hors_bareme` (section 14).

# 3 Ingestion et normalisation

## 3.1 Lecture des fichiers (étape 02)

Pour chaque feuille, la ligne d'en-tête est la première des vingt premières lignes qui contient le mot « matricule ». Les noms de colonnes sont normalisés : majuscules, accents supprimés, séparateurs remplacés par _, caractères spéciaux supprimés. Les colonnes de F2 reçoivent le suffixe `_F2` : par exemple, le code poste 124 devient `124_F2`.

F2 est rattachée à F1 par une jointure à gauche sur la clé « MATRICULE||CODE ORGANISME », après suppression des espaces et passage en majuscules. Le traitement d'un fichier s'arrête si F2 n'est pas vide et qu'aucune de ses lignes ne trouve de correspondance dans F1. Toutes les valeurs sont conservées en texte dans la couche Bronze.

## 3.2 Standardisation (étape 03)

**Noms de colonnes.** Chaque colonne est renommée vers un nom standard à l'aide d'expressions régulières, par exemple `matricule`, `sexe`, `situation`, `organisme`, `emploi`, `grade` (classe-échelon), `statut_fonctionnaire` (colonne source « GRADE »), `montant_brut` ou `montant_net`. Ces expressions sont définies dans le script de l'étape 03.

**Période.** La variable `mois_annee` est le nom du fichier mensuel, au format MMAAAA (par exemple `012015`). La valeur éventuellement présente dans le fichier n'est pas utilisée. Toute la suite de la chaîne suppose ce format.

**Situations administratives retenues.** La situation est normalisée (majuscules, accents et espaces superflus supprimés), puis comparée à trois catégories :

— *en activité* : « EN ACTIVITE », « ACTIVITE » ;
— *régularisation d'indemnités* : « REGUL. INDEMNITES », « REGUL INDEMNITES », « REGULARISATION INDEMNITES » ;
— *demi-solde* : « DEMI-SOLDE », « DEMI SOLDE », « DEMISOLDE », « 1/2 SOLDE ».

Seules les lignes de ces trois catégories sont conservées. C'est le seul filtre de population appliqué avant la construction du panel.

**Codification ANSTAT.** Huit codes sont ajoutés par correspondance exacte des libellés normalisés avec les onglets du référentiel ANSTAT :

| Code ajouté | Libellé source | Variables ajoutées en plus |
|---|---|---|
| `CODE_AFFECTATION` | lieu d'affectation | codes région, site, DRB, département ; montant transport |
| `CODE_ORGANISME` | organisme | codes établissement et ACCT |
| `CODE_POSITION_SOLDE` | situation | – |
| `CODE_EMPLOI` | emploi | grade administratif associé, `Code_CITP`, `Metier_CITP` |
| `CODE_SERVICE` | service | – |
| `CODE_FONCTION` | fonction | – |
| `CODE_GRADE` | classe-échelon | – |
| `CODE_POSTE` | poste | – |

Le `CODE_ORGANISME` utilisé dans toute la suite est donc le code ANSTAT obtenu par le libellé de l'organisme. Un libellé sans correspondance laisse le code vide.

**Montants.** Les montants de F1 et toutes les colonnes de codes postes de F2 sont convertis en nombres, après suppression des espaces et remplacement de la virgule décimale. Une valeur non convertible devient manquante.

# 4 Unité statistique et période

### 4.1 Identifiants

L'agent est identifié par son `matricule`. La variable `cle_unique` reprend la colonne source « MATRICULE||CODE ORGANISME » ; elle distingue les postes d'un même agent dans plusieurs organismes.

### 4.2 Unité d'observation

Jusqu'à la couche Silver, une ligne correspond à un poste d'un agent pour un mois. À partir du panel (étape 06), l'unité est l'**agent** × **mois** (`matricule` × `mois_annee`) : les postes d'un même agent sur un même mois sont regroupés (section 6).

### 4.3 Période

Le panel couvre tous les fichiers mensuels disponibles, à partir de janvier 2015. Les indicateurs de revenu ne portent que sur les années 2024 et suivantes (section 8).

## 5 Imputations en couche Silver

### 5.1 Grade

Le grade est extrait de la colonne `statut_fonctionnaire` par le motif « Catégorie X », où X est une lettre A, B, C ou D suivie éventuellement d'un chiffre (par exemple « Catégorie A3 » donne A3). Une valeur vide, ou qui ne contient pas ce motif, reçoit la valeur `NF` (non fonctionnaire). Les agents NF ne sont jamais imputés.

Les grades valides sont :

$$\{A3, A4, A5, A6, A7, B1, B3, C1, C2, C3, D1, D2\}$$

Un grade extrait mais absent de cette liste (par exemple A1 ou B2) est imputé par le grade le plus fréquent parmi les agents de même emploi ayant un grade valide, selon la cascade suivante :

1. même emploi, même mois et même année ;
2. à défaut, même emploi et même année ;
3. à défaut, même emploi sur tout l'historique.

L'emploi est le libellé source. Les fréquences sont calculées sur toutes les lignes Silver à grade valide, toutes années confondues. La variable `GRADE_SOURCE` trace l'origine du grade :

— `OBSERVE` : grade valide dans la source ;
— `IMPUTE` : grade invalide remplacé par un grade valide ;
— `NF_NON_IMPUTABLE` : agent NF, ou grade invalide qu'aucun niveau de la cascade n'a pu remplacer. Dans ce second cas, le grade invalide est conservé, et l'agent sort du périmètre à l'étape 07.

### 5.2 Montants brut et net

Les montants `montant_brut` et `montant_net` manquants sont imputés indépendamment l'un de l'autre, en trois temps :

1. **report avant** : dernière valeur observée du même agent (`cle_unique`, à défaut `matricule`) dans un mois antérieur, sans limite de durée ;
2. **report arrière** : à défaut, première valeur observée dans un mois postérieur ;
3. **médiane de cellule** : à défaut, médiane des valeurs observées dans la première cellule suffisamment peuplée de la cascade suivante.

| Niveau | Cellule | Effectif minimum |
|---|---|---|
| L1 | emploi × grade × organisme × mois | 5 |
| L2 | emploi × grade × mois | 5 |
| L3 | grade × organisme × mois | 3 |
| L4 | grade × mois | 3 |

Les médianes portent sur les valeurs observées avant imputation, zéros compris. Les effectifs minimum peuvent être modifiés par les variables d'environnement `MIN_OBS_L1` à `MIN_OBS_L4`. Les reports ne créent aucun mois manquant : ils ne remplissent que des lignes existantes dont le montant est vide.

Les variables `montant_brut_SOURCE` et `montant_net_SOURCE` prennent les valeurs `OBSERVE`, `LOCF_FWD`, `LOCF_BWD`, `IMPUTE_L1` à `IMPUTE_L4`, ou `NON_IMPUTABLE` si aucune méthode n'a abouti.

Les codes postes de F2, qui servent à construire M1, ne sont pas imputés.

### 5.3 Contrôles de qualité (étape 04)

L'étape 04 signale, sans bloquer la chaîne : les colonnes clés complétées à moins de 95 %, les colonnes dont le taux de valeurs manquantes varie fortement d'une année à l'autre, les doublons `matricule` × mois, les lignes où le net dépasse le brut, et la répartition par situation. Ces contrôles portent sur les montants après imputation.

## 6 Construction du panel

### 6.1 Unicité et multi-postes

Pour chaque année, l'étape 06 vérifie d'abord l'unicité du triplet :

$$\texttt{matricule} \times \texttt{mois_annee} \times \texttt{CODE_ORGANISME}$$

La présence de doublons à l'intérieur d'un même organisme arrête la compilation, car elle rendrait incertain le calcul des montants mensuels.

Un agent peut occuper plusieurs postes un même mois, dans des organismes différents. Les montants sont alors additionnés sur l'ensemble de ses postes, et `NB_POSTES` compte le nombre de postes de l'agent sur le mois. Les autres variables (grade, emploi, organisme, sexe, secteur) sont celles de la première ligne de l'agent pour ce mois.

### 6.2 Variables de revenu construites

| Variable | Construction, sommée sur les postes de l'agent |
|---|---|
| `montant_brut_sans_ind_sans_alloc` | Codes postes F2 124 + 228 + 271 + 425 (mesure M1). Un code absent compte pour 0. |
| `montant_brut_total` | Montant brut de F1, tous codes postes confondus (mesure M2). |
| `montant_representation_461_464` | Codes postes F2 461 à 464, avec le détail `montant_461` à `montant_464`. Les quatre colonnes doivent exister dans F2, sinon la compilation s'arrête. |
| `montant_brut_controle_m2` | `montant_brut_total` − `montant_representation_461_464`. Sert uniquement au contrôle de conformité M2. |
| `montant_net_total` | Montant net de F1. |

Un agent dont F2 est vide a donc un M1 égal à 0. Il est exclu des indicateurs à l'étape 07.

## 7 Définitions du revenu

### 7.1 M1 : salaire strict de référence

La mesure principale du revenu mensuel est le salaire strict de référence, somme de quatre composantes communes à tous les agents :

| Code poste | Composante |
|---|---|
| 124 | Salaire de base |
| 228 | Indemnité de transport |
| 271 | Indemnité de logement |
| 425 | Indemnité de résidence |

$$M1 = \texttt{montant_brut_sans_ind_sans_alloc} = 124 + 228 + 271 + 425$$

L'allocation familiale, code 421, est exclue. Elle n'entre pas dans la définition de l'agrégat de masse salariale retenue par le manuel de statistiques de finances publiques du FMI, et introduirait un biais lié à la situation familiale de l'agent.

### 7.2 M2 : salaire brut total

La seconde mesure est le montant brut total versé à l'agent, tous codes postes confondus, y compris les indemnités spécifiques et l'allocation familiale :

$$M2 = \texttt{montant_brut_total} = \sum_{\text{postes}} \texttt{montant_brut}$$

Les indicateurs M2 portent sur ce montant complet. En revanche, la conformité au barème M2 est appréciée sur le montant diminué des codes postes 461 à 464 (`montant_brut_controle_m2`), qui ne figurent pas dans le barème total de référence.

### 7.3 M3 : salaire brut total hors barèmes spécifiques

La mesure M3 reprend M2 sur une population restreinte : elle exclut les barèmes des magistrats, des greffiers, du corps préfectoral, du corps diplomatique et de la police, dont les indemnités spécifiques ne sont pas comparables à la grille générale.

## 8 Population retenue

### 8.1 Filtres communs (étape 07)

Les filtres suivants sont appliqués successivement à toute la base, et valent donc pour M1, M2 et M3 :

1. **organisme 59** exclu : il correspond aux représentations nationales à l'étranger, dont les agents bénéficient d'indemnités spécifiques non comparables à la grille nationale ;
2. **période** : années 2024 et suivantes. Il n'y a pas de borne supérieure : les mois de 2026 disponibles sont inclus ;
3. **sexe** : les valeurs sont harmonisées en « Homme » et « Femme » ; les observations au sexe non interprétable sont exclues de toute la base, et pas seulement des ventilations par sexe ;
4. **grade** : seuls les douze grades valides sont retenus, ce qui exclut les agents NF ;
5. **barème police** exclu ;
6. **salaire strict** : les observations dont M1 est manquant ou égal à 0 sont exclues, y compris pour M2 et M3.

### 8.2 Exclusions propres à chaque mesure (étape 07b)

| Mesure | Population | Exclusions supplémentaires |
|---|---|---|
| M1 | `Statut` conforme | Barèmes magistrats, greffiers, corps préfectoral, corps diplomatique, police |
| M2 | `Statut_Total` conforme | Aucune |
| M3 | `Statut_Total` conforme | Mêmes barèmes que M1 |

Les barèmes spécifiques sont exclus de M1 pour la même raison que l'organisme 59 : leurs indemnités ne sont pas comparables à la grille générale.

Les observations « conformes » comprennent les agents conformes d'origine, les agents repêchés par la tolérance de 5 % (section 9) et les agents corrigés à l'étape 07a (section 10).

# 9 Conformité au barème

## 9.1 Secteur de barème

Chaque agent est rattaché à un secteur de barème à partir de son emploi, par correspondance exacte du libellé normalisé avec le fichier `CORRESPONDANCE_GRILLE_EMPLOI.xlsx`. Deux corrections s'appliquent aux agents du barème général : les emplois d'informaticien sont rattachés au barème « Informaticien », et les emplois de secrétaire au barème « Secrétaire de direction ».

Les secteurs utilisés par le code sont : enseignement primaire et secondaire, enseignement supérieur, cadres supérieurs de santé, personnels techniques de santé, paramilitaire, barème général, informaticien, secrétaire de direction, magistrats, corps préfectoral, corps diplomatique, greffiers. Le barème police est exclu de la population. La liste effective dépend du fichier de correspondance.

## 9.2 Bornes de référence

Le référentiel `anstat_2025` fournit, par secteur et grade, des salaires de référence :

— référence M1 : somme des composantes « Salaire de base », « Résidence », « Logement » et « Transport » du référentiel ;
— référence M2 : salaire brut total du référentiel.

Pour chaque couple secteur $\times$ grade, les bornes sont le minimum et le maximum des valeurs de référence strictement positives du référentiel, arrondis à l'unité : `min_bareme` et `max_bareme` pour M1, `min_total` et `max_total` pour M2.

## 9.3 Statuts

Pour M1, le salaire strict est comparé aux bornes M1. Pour M2, `montant_brut_controle_m2` est comparé aux bornes M2 :

$$\texttt{Statut} = \begin{cases} \text{Conforme au barème} & \text{si } min \leq x \leq max \\ \text{Inférieur au minimum du barème} & \text{si } x < min \\ \text{Supérieur au maximum du barème} & \text{si } x > max \\ \text{Cluster non déterminé} & \text{si les bornes sont absentes} \end{cases}$$

Les variables produites sont `Statut` (M1) et `Statut_Total` (M2). `Statut_Total` vaut « Non calculé » si le référentiel M2 est indisponible.

## 9.4 Tolérance de 5 %

Un agent hors bornes est reclassé « Conforme au barème » lorsque l'écart relatif à la borne franchie est strictement inférieur à 5 % :

$$\frac{min - x}{min} < 5\,\% \quad \text{ou} \quad \frac{x - max}{max} < 5\,\%$$

Cette règle s'applique à M1 et à M2, avant la correction des hors-barème temporaires.

# 10 Correction des hors-barème temporaires

Un agent est éligible à la correction s'il compte entre un et cinq mois hors barème (inférieur ou supérieur) sur l'ensemble de la période d'analyse, consécutifs ou non. M1 et M2 sont traités séparément.

Pour chaque mois hors barème d'un agent éligible, la valeur est remplacée par celle du mois conforme le plus proche dans le temps, au sein du groupe :

$$\texttt{matricule} \times \texttt{GRADE} \times \texttt{emploi} \times \texttt{CODE_ORGANISME}$$

Il n'y a pas de distance maximale. En cas d'égalité de distance, la valeur passée est retenue. La valeur de remplacement n'est conservée que si elle se situe strictement dans les bornes du barème, sans la tolérance de 5 %. Dans le cas contraire, la valeur observée est restaurée et le statut hors barème est conservé.

Pour M2, la correction remplace, depuis le même mois conforme, `montant_brut_controle_m2`, `montant_brut_total` et les montants des codes 461 à 464. Les indicateurs M2 portent donc en partie sur des montants remplacés.

Les variables `montant_brut_sans_ind_sans_alloc_source` et `montant_brut_total_source` valent `IMPUTE` ou `OBSERVE`.

# 11 Gouvernance des règles sensibles

Les traitements suivants sont des choix méthodologiques explicites de l'ANSTAT – DDI. Ils ne doivent pas être interprétés comme de simples corrections techniques, car ils modifient la population conforme, et donc les effectifs, les quartiles et les moyennes publiés.

| Règle | Effet statistique possible | Trace dans le pipeline |
|---|---|---|
| Tolérance de 5 % autour des bornes de barème | Reclasse des agents hors barème en conformes, ce qui augmente la population des indicateurs M1, M2 et M3. | Distributions avant et après repêchage dans le journal de l'étape 07. |
| Correction des hors-barème temporaires | Remplace une valeur hors barème par la valeur conforme la plus proche, pour les agents ayant de 1 à 5 mois hors barème. | `montant_brut_sans_ind_sans_alloc_source` et `montant_brut_total_source` (étape 07a). |
| Imputation des grades | Réintègre dans le périmètre des agents dont le grade source est invalide. | `GRADE_SOURCE` : `OBSERVE`, `IMPUTE`, `NF_NON_IMPUTABLE`. |
| Imputation des salaires | Rend exploitables des observations dont le montant brut ou net était manquant. | `montant_brut_SOURCE` et `montant_net_SOURCE` : `OBSERVE`, `LOCF_FWD`, `LOCF_BWD`, `IMPUTE_L1` à `IMPUTE_L4`, `NON_IMPUTABLE`. |
| Exclusion des barèmes spécifiques en M1 et M3 | Retire magistrats, greffiers, corps préfectoral, corps diplomatique et police des indicateurs M1 et M3. | Journal de l'étape 07b. |
| Exclusion des codes 461 à 464 du contrôle M2 | Modifie la population conforme M2, sans changer le montant M2 publié. | `montant_brut_controle_m2` (étape 06). |
| Exclusion des sexes non interprétables | Retire ces observations de tous les indicateurs, y compris ceux qui ne sont pas ventilés par sexe. | Journal de l'étape 07. |

Toute diffusion institutionnelle doit donc mentionner la version méthodologique appliquée, c'est-à-dire la version de la présente note. En cas de changement d'une de ces règles, les séries historiques doivent être soit recalculées, soit accompagnées d'une rupture méthodologique documentée.

Les rapports de production doivent conserver au minimum les effectifs par statut avant et après repêchage, les effectifs imputés par source, ainsi que les distributions M1 et M2 utilisées pour alimenter les fichiers Excel et Superset.

# 12 Indicateurs produits

## 12.1 Unité et statistiques

Les indicateurs de l'étape 07b sont calculés par mois (`ANNEE` × `MOIS`), sur des observations agent × mois, sans pondération. Pour chaque groupe et chaque mois :

| Statistique | Définition |
|---|---|
| Effectif | Nombre de matricules distincts |
| P25, médiane, P75 | Quartiles du revenu (valeur observée la plus proche) |
| Moyenne | Moyenne arithmétique du revenu |
| Minimum, maximum | Valeurs extrêmes observées |

Toutes les statistiques sont arrondies à l'unité. La moyenne mensuelle est :

$$\overline{R}_{g,t} = \frac{1}{N_{g,t}} \sum_{i \in g,t} R_{i,t}$$

où $R_{i,t}$ désigne le revenu de l'agent $i$ au mois $t$, $g$ le groupe d'analyse et $N_{g,t}$ le nombre d'agents du groupe ce mois-là.

Pour les ventilations par grade, l'agent est classé selon son `GRADE_PRINCIPAL`, le plus élevé de ses grades sur le mois.

Une winsorisation aux 1er et 99e centiles du brut total est calculée (cellules mois × grade × CITP, repli sur mois × grade en dessous de 100 observations), mais aucune sortie ne l'utilise : **aucun indicateur publié n'est winsorisé**.

## 12.2 Indicateurs par mesure

| Mesure | Axes de ventilation |
|---|---|
| M1 | grade ; sexe × grade ; profession CITP ; sexe × trimestre ; secteur de barème ; secteur × grade ; secteur × sexe |
| M2 | secteur de barème ; secteur × grade ; secteur × sexe ; grade ; grade × sexe ; sexe ; CITP ; sexe × trimestre |
| M3 | mêmes axes que M2 |

## 12.3 Multi-postes

Les tableaux multi-postes donnent des effectifs, sans revenu : nombre d'agents par grade et par nombre de postes (1, 2, 3, 4, 5 et plus). L'unité est l'agent × année, avec le nombre maximal de postes occupés dans l'année. La population est l'ensemble du panel depuis 2024, hors NF, organisme 59 et police, sans condition de conformité au barème.

## 12.4 Autres tableaux

Le classeur technique de l'étape 07b contient aussi :

— `MODELE_ANSTAT_{année}` : minimum, moyenne, maximum et médiane de M2 sur l'ensemble des mois de l'année, par secteur de barème, l'enseignement étant séparé entre primaire (grades B3, C3, D1, D2) et secondaire ;
— `EFFECTIFS_*` : nombre d'agents distincts sur la période et par année ;
— `RESUME_STATUT` et `RESUME_STATUT_TOTAL` : nombre d'observations agent × mois par statut de conformité, après correction.

# 13 Sorties statistiques

## 13.1 Classeur final (étape 08)

L'étape 08 produit le classeur final à partir du classeur technique. Il présente M1, M2 et M3 côte à côte et contient :

— une feuille `IHPC_DONNEES` ;
— un sommaire par année, `SOMMAIRE_2024`, `SOMMAIRE_2025`, etc., avec cinq sections : CITP (grand groupe), grade, sexe, sexe × trimestre et secteur de barème ;
— des feuilles de détail mensuel par grand groupe CITP, grade, sexe, trimestre, année et secteur de barème ;
— les feuilles multi-postes et `MODELE_ANSTAT` reprises du classeur technique.

**Passage du mois à l'année.** Dans les sommaires annuels :

— l'effectif annuel est la moyenne des effectifs mensuels ;
— le revenu moyen annuel est la moyenne des revenus moyens mensuels, pondérée par les effectifs mensuels. Il est égal à la moyenne de toutes les observations agent × mois de l'année ;
— P25 et P75 sont les moyennes pondérées des quartiles mensuels. Ce ne sont pas les quartiles de la distribution annuelle.

**Revenu réel.** Chaque revenu moyen est accompagné d'un revenu réel, en francs CFA du deuxième trimestre 2024 :

$$R_t^{\text{réel}} = R_t \times \frac{\text{IHPC}_{2024T2}}{\text{IHPC}_t}, \qquad \text{IHPC}_{2024T2} = \frac{102{,}81 + 103{,}84 + 104{,}56}{3} \approx 103{,}74$$

$\text{IHPC}_t$ est l'indice moyen de l'année pour les sommaires annuels, et l'indice moyen du trimestre pour les tableaux trimestriels.

**Contrôle.** L'étape vérifie, pour huit ventilations, que le revenu moyen M2 est supérieur ou égal au revenu moyen M1. Le résultat est inscrit dans le journal, sans arrêter la chaîne.

## 13.2 Base PostgreSQL (étape 09)

L'étape 09 charge dans PostgreSQL (table `panel`) la base corrigée de l'étape 07a, avec toutes ses colonnes, dont les statuts M1 et M2. Si la base corrigée est absente, la base non corrigée de l'étape 07 est chargée, ce qui est signalé dans le journal. Le chargement remplace entièrement la table : les données sont d'abord chargées dans une table intermédiaire, le nombre de lignes est contrôlé, puis la table intermédiaire remplace la table finale. Les vues Superset, qui dépendent de cette table, sont supprimées au passage et recréées par l'étape 10.

### 13.3 Vues Superset (étape 10)

L'étape `10_validate_superset_views.py` applique le fichier `superset/superset_views.sql` dans PostgreSQL, puis interroge chaque vue attendue. Cette validation est obligatoire après chaque modification du SQL ou de la structure de la table `panel`. Elle vérifie la compilation effective des vues, la présence des colonnes requises, la non-vacuité des vues principales et la présence d'au moins une observation conforme en M1 et en M2.

Les vues appliquent l'exclusion de l'organisme 59 et la liste des douze grades valides, mais leurs conventions diffèrent de celles des fichiers Excel :

— elles couvrent toutes les années depuis 2015, et pas seulement 2024 et suivantes ;
— l'effectif compte des observations, et non des agents distincts (sauf dans la vue annuelle) ;
— les quartiles sont interpolés, alors que les fichiers Excel retiennent la valeur observée la plus proche ;
— les barèmes spécifiques ne sont pas exclus en M1, et M3 n'est pas produite.

Les chiffres de Superset ne sont donc pas directement comparables à ceux des fichiers Excel.

## 14 Traitements complémentaires

Ces traitements sont lancés séparément. Ils n'alimentent ni le classeur final, ni PostgreSQL.

### 14.1 Correction des trajectoires individuelles

Le script `10_correction_gold_trajectoire.py` harmonise, pour chaque agent, trois caractéristiques qui devraient être fixes dans le temps : le sexe, la date de naissance et la date de prise de service. La valeur retenue est la plus fréquente sur l'ensemble de l'historique de l'agent, après exclusion des dates de naissance antérieures à 1930 ou postérieures à 2010, et des prises de service antérieures à 1960. En cas d'égalité entre plusieurs valeurs, le choix n'est pas déterministe ; ces cas sont dénombrés dans un rapport dédié.

Le script calcule aussi l'âge et l'ancienneté à chaque période, et signale les incohérences de calendrier (âge hors de 16 à 80 ans, prise de service postérieure à la période, etc.) sans les corriger. Le grade, l'emploi et l'organisme ne sont pas corrigés : leurs changements sont comptés comme des mobilités. La sortie, `panel_trajectoire_clean.parquet`, est limitée aux périodes 2024 et suivantes.

**Les indicateurs officiels n'utilisent pas ces corrections** : l'étape 07 lit le panel de l'étape 06.

### 14.2 Salaire par expérience

L'étape `11_analyse_salaire_experience.py` croise le panel corrigé des trajectoires avec la base corrigée de l'étape 07a. L'expérience est la durée, en années de 365,25

jours, entre la prise de service corrigée et le premier jour du mois d'observation. Elle est regroupée en classes de cinq ans, de « 0 - 5 » à « 40 - 45 », puis « 45+ ».

La population est celle des observations conformes (`Statut` pour M1, `Statut_Total` pour M2), depuis 2024, hors organisme 59, hors magistrats, greffiers, corps préfectoral et corps diplomatique, avec une expérience positive et un salaire strictement positif. Les statistiques sont celles de l'étape 07b, avec en plus le nombre d'observations. Elles sont produites globalement et par année, sexe, situation matrimoniale, grade et CITP.

Le script `plus_age_experience.py` liste les observations dont l'expérience dépasse un seuil choisi par l'utilisateur. Ses critères diffèrent de ceux de l'étape 11 : il exclut aussi le barème paramilitaire, ne filtre pas sur le statut de conformité et mesure M2 hors codes 461 à 464.

### 14.3 Exports

`export_salaires_sexe.py` produit les salaires moyens M1 par sexe, mensuels et trimestriels, de 2024 à l'année en cours, sur les observations conformes à salaire strictement positif. Les barèmes spécifiques n'y sont pas exclus, et l'effectif trimestriel compte des observations agent × mois.

`export_liste_hors_bareme.py` liste les observations hors barème M1 (inférieures au minimum ou supérieures au maximum), avec des récapitulatifs par grade et par organisme. Il lit un fichier que la chaîne actuelle ne produit plus : il n'est pas exploitable en l'état.

## 15 Limites d'interprétation

**Limites d'interprétation**

Les indicateurs sont des statistiques administratives fondées sur les données de paie disponibles et les référentiels ANSTAT. Toute modification de nomenclature, de grille salariale ou de structure des fichiers sources doit être documentée et, si nécessaire, intégrée dans les référentiels avant toute comparaison temporelle.

**Limites connues.**

- Les bornes de conformité proviennent d'un référentiel unique, `anstat_2025`, appliqué à toutes les années d'analyse depuis 2024 : une revalorisation de la grille en cours de période ne serait pas prise en compte.
- Le secteur de barème dépend de la correspondance exacte du libellé de l'emploi. Un emploi absent du fichier de correspondance donne un statut « Cluster non déterminé ».
- Les quartiles annuels des sommaires sont des moyennes de quartiles mensuels.
- Les chiffres de Superset et ceux des fichiers Excel ne sont pas calculés avec les mêmes conventions.
- Les analyses complémentaires (expérience, exports) appliquent leurs propres critères de population, décrits à la section 14. Leurs chiffres ne se comparent pas directement aux indicateurs officiels.

# 16 Synthèse méthodologique

La chaîne de production applique la séquence suivante :

1. ingestion des fichiers mensuels de paie et rattachement du détail des codes postes (F2) à la feuille principale (F1) ;
2. standardisation des colonnes, filtre des situations administratives (activité, régularisation d'indemnités, demi-solde) et codification ANSTAT ;
3. extraction et imputation du grade, imputation des montants brut et net manquants ;
4. constitution d'un panel agent $\times$ mois, avec regroupement des multi-postes ;
5. calcul des mesures M1 (codes 124, 228, 271, 425) et M2 (brut total) ;
6. restriction aux années 2024 et suivantes, aux douze grades valides, hors organisme 59, police et sexes non interprétables ;
7. calcul des statuts de conformité au barème, avec tolérance de 5 % ;
8. correction des hors-barème temporaires (1 à 5 mois) ;
9. production des indicateurs M1, M2 et M3 par grade, sexe, CITP, trimestre et secteur de barème ;
10. diffusion par le classeur Excel final (avec revenus réels), PostgreSQL et Superset.

Cette méthodologie concilie la définition statistique du revenu moyen avec les contraintes des données administratives, tout en conservant la traçabilité nécessaire à une production institutionnelle.